

INFORME EJECUTIVO

Predicción de Calidad de Vino

Wine Quality Dataset, UCI

Equipo 8

- Daniela Iliana Sierra Rendón
- David López Sánchez
- Lenin Hernández Arias

Junio de 2026

1. Resumen Ejecutivo

El presente proyecto tuvo como objetivo desarrollar y comparar diferentes modelos de aprendizaje supervisado para predecir la calidad del vino utilizando el conjunto de datos **Wine Quality** de la UCI Machine Learning Repository, integrando información de vinos tintos y blancos. La variable objetivo fue la calificación de calidad asignada a cada vino, por lo que el problema se abordó como una tarea de regresión.

En la primera etapa se realizó la exploración y preprocesamiento de los datos. Se verificó la existencia de valores faltantes, se analizaron las distribuciones y correlaciones entre variables, se incorporó una variable indicadora para distinguir entre vinos tintos y blancos, y se aplicó el escalamiento de las variables numéricas para garantizar un adecuado desempeño de los modelos sensibles a la magnitud de los datos.

Posteriormente, se establecieron modelos base mediante Regresión Lineal, Ridge y Lasso, con el objetivo de contar con una referencia inicial y analizar el efecto de las técnicas de regularización. Los resultados mostraron un desempeño similar entre los modelos lineales, mientras que Lasso eliminó algunas variables poco relevantes al reducir sus coeficientes a cero, facilitando la interpretación del modelo.

En una tercera etapa se entrenaron modelos más avanzados basados en ensambles y redes neuronales, incluyendo Random Forest, AdaBoost, XGBoost y un Perceptrón Multicapa (MLP). La comparación de métricas permitió identificar que **Random Forest obtuvo el mejor desempeño**, alcanzando los menores errores de predicción (MAE y RMSE) y el mayor coeficiente de determinación (R^2), lo que evidencia su capacidad para capturar relaciones no lineales presentes en las propiedades fisicoquímicas del vino y su percepción de calidad.

Adicionalmente, se realizó un experimento para comparar el efecto de optimizar distintas funciones de pérdida (MSE y MAE) utilizando árboles de decisión. Este análisis permitió observar cómo la función de pérdida utilizada durante el entrenamiento influye en el comportamiento del modelo, especialmente cuando existen valores atípicos, mostrando que la optimización basada en MAE resulta más robusta frente a este tipo de observaciones.

Finalmente, se realizó una comparación integral de todos los modelos considerando tanto su desempeño predictivo como su interpretabilidad. Además de identificar al modelo con mejores resultados, se analizaron las variables más influyentes mediante la importancia de variables de Random Forest y los coeficientes obtenidos con Lasso y Ridge, permitiendo comprender no solo cuál modelo ofreció el mejor rendimiento, sino también las razones que explican dicho comportamiento.

2. Exploración y Procesamiento

2.1 Descripción de la base de datos

Se combinaron los dos subconjuntos del Wine Quality Dataset (red + white en una sola tabla de 6,497 filas y 13 variables fisicoquímicas, añadiendo una variable que indica el tipo de vino (tinto/blanco) para capturar diferencias entre variantes.

No se identificaron valores nulos en ninguna de las variables del conjunto de datos, por lo que, no fue necesario realizar procesos de imputación.


Las variables son las siguientes:

#	Column	Non-Null Count	Dtype
0	fixed acidity	6497 non-null	float64
1	volatile acidity	6497 non-null	float64
2	citric acid	6497 non-null	float64
3	residual sugar	6497 non-null	float64
4	chlorides	6497 non-null	float64
5	free sulfur dioxide	6497 non-null	float64
6	total sulfur dioxide	6497 non-null	float64
7	density	6497 non-null	float64
8	pH	6497 non-null	float64
9	sulphates	6497 non-null	float64
10	alcohol	6497 non-null	float64
11	quality	6497 non-null	int64
12	category white	6497 non-null	bool

2.2 Estadísticos descriptivos


	count	mean	std	min	25%	50%	75%	max
fixed acidity	6497.0	7.215307	1.296434	3.80000	6.40000	7.00000	7.70000	15.90000
volatile acidity	6497.0	0.339666	0.164636	0.08000	0.23000	0.29000	0.40000	1.58000
citric acid	6497.0	0.318633	0.145318	0.00000	0.25000	0.31000	0.39000	1.66000
residual sugar	6497.0	5.443235	4.757804	0.60000	1.80000	3.00000	8.10000	65.80000
chlorides	6497.0	0.056034	0.035034	0.00900	0.03800	0.04700	0.06500	0.61100
free sulfur dioxide	6497.0	30.525319	17.749400	1.00000	17.00000	29.00000	41.00000	289.00000
total sulfur dioxide	6497.0	115.744574	56.521855	6.00000	77.00000	118.00000	156.00000	440.00000
density	6497.0	0.994697	0.002999	0.98711	0.99234	0.99489	0.99699	1.03898
pH	6497.0	3.218501	0.160787	2.72000	3.11000	3.21000	3.32000	4.01000
sulphates	6497.0	0.531268	0.148806	0.22000	0.43000	0.51000	0.60000	2.00000
alcohol	6497.0	10.491801	1.192712	8.00000	9.50000	10.30000	11.30000	14.90000
quality	6497.0	5.818378	0.873255	3.00000	5.00000	6.00000	6.00000	9.00000


2.3 Distribución de la variable objetivo



La mayoría de las observaciones presentan calificaciones entre 5 y 6, mientras que las calidades extremas aparecen con mucha menor frecuencia.

2.4 Matriz de correlación








Se observa una correlación positiva entre el contenido de alcohol, mientras que la densidad y la acidez volátil presenta una correlación negativa. La mayoría de las variables presentan correlaciones bajas o moderadas, por lo que no existe evidencia de una multicolinealidad severa.

2.5 Valores atípicos

Graficamos los box-plot de las variables más correlacionadas





2.3 Escalamiento

Debido a que modelos como Ridge, Lasso y la Red Neuronal son sensibles a la escala de las variables, se aplicó una estandarización mediante StandardScaler antes del entrenamiento.

3. Modelos Base y de Regularización

3.1 Métrica principal: MAE sobre MSE

La métrica de evaluación y optimización fue el Error Absoluto Medio (MAE) por tres razones:

- El MSE eleva al cuadrado cada error, por lo que un error de 2 puntos pesa más que uno de 1 punto, sesgando al modelo a evitar errores grandes a costa de precisión general.
- El MAE refleja el costo de negocio real: un lote mal evaluado en 1 o 2 puntos tiene un costo aproximadamente proporcional, no cuadrático.
- El MAE es más robusto frente a los outliers.

3.2 Participación y validación

División: 75% entrenamiento (4,872 muestras) / 25% prueba (1,625 muestras), con muestreo estratificado por nivel de calidad (parámetro stratify=y) para preservar las proporciones de clases minoritarias. Los hiperparámetros de todos los modelos se ajustaron mediante GridSearchCV con validación cruzada de 10 folds, optimizando MAE.

Modelo	Tipo	Hiperparámetros explorados	Combinaciones
Regresión Lineal	GLM baseline	Ninguno (baseline)	1
LASSO (L1)	GLM regularizado	alpha: {0.001, 0.01, 0.05, 0.1, 0.5, 1.0}	60


Ridge (L2)	GLM regularizado	alpha: {0.01, 0.1, 1.0, 10.0, 100.0}	50
Random Forest	Ensamble bagging	n_estimators, max_depth, min_samples_split, max_features	240
AdaBoost	Ensamble boosting	n_estimators, learning_rate, profundidad del árbol base	180
XGBoost	Ensamble boosting	Early stopping, subsample, colsample_bytree, reg_alpha/lambda	Early stop
MLP	Red neuronal	Arquitectura (1-3 capas), activación, alpha L2, lr_init	360

3.3 Regresión Lineal (Baseline)

La regresión lineal establece el piso de comparación con $MAE \approx 0.581$ y $R^2 \approx 0.2863$. El gráfico de predicho vs. real muestra que las predicciones se concentran en un rango estrecho (≈ 5 a 6.5), incapaces de seguir los valores extremos reales. Esto revela la primera limitación estructural de los modelos lineales: asumen que el efecto de cada variable sobre la calidad es aditivo y constante, sin posibilidad de capturar umbrales (por ejemplo, que un alcohol muy alto en combinación con baja densidad sea especialmente bueno).

Adicionalmente, el estadístico Mallows' Cp confirma que el modelo no está sobreajustado: el problema no es varianza, sino sesgo.

MAE: 0.5809
MSE: 0.5444
RMSE: 0.7378
 R^2 : 0.5524




3.4 LASSO (L1)

GridSearchCV seleccionó $\alpha = 0.001$ (prácticamente sin regularización) con MAE CV ≈ 0.568 , virtualmente idéntico al baseline lineal. Esto tiene una interpretación directa:

- LASSO no eliminó ninguna variable (todos los coeficientes permanecen distintos de cero), lo que indica que no hay multicolinealidad severa que justifique penalizar coeficientes.
- La regularización L1, al forzar sparsity, podría en principio mejorar si hubiera muchas variables irrelevantes. Pero con solo 11 predictores bien elegidos fisicoquímicamente, la sparsity no aporta.
- El límite MAE ≈ 0.56 refleja que la relación entre variables fisicoquímicas y calidad tiene componentes no lineales que ningún modelo lineal puede capturar, independientemente del nivel de regularización

MAE : 0.5676
MSE : 0.5809
RMSE : 0.7377
 R^2 : 0.2865



3.5 Ridge (L2)

Ridge con $\alpha = 0.01$ encoge los coeficientes hacia cero pero nunca los anula, lo que es apropiado cuando se sospecha multicolinealidad. La regularización L2 cumple exitosamente su función de estabilizar los coeficientes y reducir la varianza, pero es incapaz de extraer relaciones no lineales. El verdadero desafío predictivo del vino radica en patrones complejos que ningún modelo lineal, por más regularizado que esté, puede capturar.

MAE : 0.5673
MSE : 0.7627
RMSE : 0.7378
 R^2 : 0.2863

4. Modelos de Ensamble y Redes


4.1 Random Forest

Random Forest es un algoritmo de aprendizaje supervisado basado en la técnica de **bagging**, que construye múltiples árboles de decisión utilizando subconjuntos aleatorios de observaciones y variables. La predicción final corresponde al promedio de las predicciones de todos los árboles, lo que reduce la varianza y disminuye el riesgo de sobreajuste respecto a un árbol individual.


Para obtener el mejor desempeño posible del modelo se utilizó GridSearchCV con validación cruzada de 10 particiones. Este procedimiento evalúa múltiples combinaciones de hiperparámetros y selecciona aquella que minimiza el Error Absoluto Medio (MAE), reduciendo la posibilidad de sobreajuste.

MAE:	0.4325
MSE:	0.3603
RMSE:	0.6002
R^2 :	0.5276

La mayoría de las observaciones se concentran alrededor de la línea de predicción perfecta, indicando que el modelo es capaz de aproximar adecuadamente la calidad del vino, aunque aún existen errores para algunas observaciones.



La importancia de variables muestra cuáles características influyen más en la predicción de la calidad del vino. Tanto la importancia nativa del modelo (MDI) como la importancia por permutación coinciden en señalar que variables como el contenido de alcohol, la densidad y los sulfatos son determinantes para explicar la calidad del vino.



4.2 Adaboost

AdaBoost (Adaptive Boosting) es un algoritmo de ensamble basado en boosting que combina múltiples árboles de decisión pequeños (weak learners). A diferencia de Random Forest, que construye los árboles de manera independiente, AdaBoost los construye de forma secuencial, donde cada nuevo árbol intenta corregir los errores cometidos por los árboles anteriores. De esta forma transforma varios modelos débiles en un modelo predictivo más robusto.


Sus limitaciones en este contexto son:

- **Sensibilidad al ruido:** el dataset tiene etiquetas de calidad asignadas por catadores humanos con variabilidad inherente (acuerdo entre catadores no perfecto). AdaBoost, al focalizarse iterativamente en los errores, puede sobreajustar estos puntos ruidosos.
- **Sensibilidad al desbalance:** con muy pocas muestras de calidad extrema, AdaBoost tiende a ponderar excesivamente esos casos como 'difíciles', distorsionando el modelo para la mayoría de los datos.
- **Sobreajuste:** La curva de error por iteración muestra que el MAE se estabiliza y en algunos casos empeora ligeramente después del óptimo, confirmando una tendencia al sobreajuste con muchos árboles.


Al igual que Random Forest, se utilizó GridSearchCV con validación cruzada de 10 particiones. Este procedimiento evalúa múltiples combinaciones de hiperparámetros y selecciona aquella que minimiza el Error Absoluto Medio (MAE), reduciendo la posibilidad de sobreajuste.

MAE:	0.5625
MSE:	0.4978
RMSE:	0.7055
R^2 :	0.3473

La gráfica compara la calidad real del vino con la calidad estimada por AdaBoost. Si el modelo fuera perfecto, todas las observaciones se ubicarían sobre la línea diagonal. Se observa que la mayoría de las predicciones se concentran alrededor de dicha línea; sin embargo, existe una dispersión considerable, especialmente para las calidades más bajas y más altas. Esto indica que el modelo presenta una precisión moderada y tiende a cometer errores de predicción mayores que Random Forest.



La siguiente curva muestra cómo evoluciona el Error Absoluto Medio conforme AdaBoost incorpora nuevos árboles de decisión al ensamble. Inicialmente el error disminuye de manera importante, ya que cada nuevo árbol corrige los errores de los anteriores. Posteriormente la mejora se estabiliza, indicando que agregar un mayor número de árboles produce beneficios cada vez menores y puede incluso favorecer el sobreajuste. El punto de menor MAE representa el número óptimo de iteraciones seleccionado para el modelo.




4.3 XGBoost

XGBoost (Extreme Gradient Boosting) es un algoritmo de aprendizaje supervisado basado en boosting. Al igual que AdaBoost, construye árboles de decisión de forma secuencial, donde cada nuevo árbol intenta corregir los errores de los anteriores. Sin embargo, incorpora técnicas avanzadas como regularización L1 y L2, subsampling, early stopping y optimización mediante gradientes de segundo orden, lo que le permite obtener un mejor desempeño y reducir el sobreajuste.


Al igual que los modelos anteriores evalúa múltiples combinaciones de hiperparámetros y selecciona aquella que minimiza el Error Absoluto Medio (MAE), reduciendo la posibilidad de sobreajuste.

MAE: 0.4845
MSE: 0.4094
RMSE: 0.6399
 R^2 : 0.4632

La mayoría de las predicciones se concentran alrededor de la diagonal, indicando que XGBoost es capaz de aproximar adecuadamente la calidad del vino. La dispersión observada refleja los errores de predicción, principalmente en las categorías menos frecuentes.



La curva de aprendizaje muestra la evolución del RMSE durante el entrenamiento. Inicialmente el error disminuye de manera importante conforme se agregan árboles; posteriormente la mejora se estabiliza. El algoritmo detiene automáticamente el entrenamiento cuando el desempeño deja de mejorar, evitando el sobreajuste.



4.4 Multi Layer Perceptron (MLP)


El MLP (Multi Layer Perceptron) es una red neuronal artificial que aprende relaciones complejas entre las variables de entrada y la variable objetivo.

A diferencia de la regresión lineal, no asume que la relación sea lineal, por lo que puede capturar patrones mucho más complicados.


Se obtienen las siguientes métricas:

MAE:	0.5267
MSE:	0.4639
RMSE:	0.6811
R^2 :	0.3918

La gráfica compara los valores reales de la calidad del vino con los valores predichos por la red neuronal. Cuanto más cercanos estén los puntos a la línea diagonal, mayor es la precisión del modelo.



La función de pérdida disminuye conforme avanzan las épocas de entrenamiento, indicando que la red neuronal fue ajustando sus pesos para minimizar el error.



5. Optimización de Funciones de Pérdida

5.1 Modelos que optimizan funciones pérdidas

Debido a que se trabajó como regresión, la forma más sencilla es comparar dos modelos que optimizan pérdidas diferentes.

Modelo	Función de pérdida
Regresión Lineal	MSE (Mean Squared Error)
Regresión Cuantílica	MAE ((Mean Absolute Error)

5.2 Modelo que optimiza MSE

Primero construimos un Pipeline. Esto garantiza que antes de entrenar el modelo todas las variables tengan la misma escala mediante StandardScaler. Después se aplica la Regresión Lineal, cuyo objetivo es minimizar el Error Cuadrático Medio (MSE).

Estas son algunas predicciones del modelo. Observamos que los valores estimados son cercanos a la calidad real, aunque existe un pequeño error, lo cual es normal en un modelo de regresión.

Primeras predicciones del modelo:

	Calidad Real	Calidad Predicha
0	5	5.93
1	6	5.67
2	5	5.19
3	6	6.22
4	5	5.39
5	5	6.06
6	6	5.41
7	5	4.99
8	5	5.21
9	5	5.29

Estos son los coeficientes de cuánto influye una variable sobre la calidad del vino.

- Coeficientes positivos incrementan la calidad estimada.
- Coeficientes negativos disminuyen la calidad estimada.

Coeficientes del modelo:		
	Variable	Coeficiente
7	density	-0.319428
3	residual sugar	0.307298
10	alcohol	0.267350
1	volatile acidity	-0.258843
11	category_white	-0.174085
0	fixed acidity	0.110206
9	sulphates	0.104290
8	pH	0.082758
5	free sulfur dioxide	0.081817
6	total sulfur dioxide	-0.072621
4	chlorides	-0.019973
2	citric acid	-0.017469

5.3 Modelo que optimiza MAE

Primero construimos un Pipeline. Esto garantiza que antes de entrenar el modelo todas las variables tengan la misma escala mediante StandardScaler. Después se aplica QuantileRegressor, cuyo objetivo es minimizar el Error Absoluto Medio (MAE). A diferencia del MSE, esta función de pérdida asigna el mismo peso a todos los errores, por lo que el modelo es menos sensible a valores atípicos.

De igual manera obtenemos algunas predicciones del modelo.

Primeras predicciones:

	Calidad Real	Calidad Predicha
0	5	5.86
1	6	5.68
2	5	5.21
3	6	6.16
4	5	5.31
5	5	6.00
6	6	5.29
7	5	4.96
8	5	5.15
9	5	5.20

Coeficientes obtenidos con MAE

Coeficientes del modelo MAE:		
	Variable	Coeficiente
0	density	-0.312795
1	residual sugar	0.310346
2	alcohol	0.288939
3	volatile acidity	-0.239562
4	fixed acidity	0.156333
5	sulphates	0.125920
6	total sulfur dioxide	-0.122353
7	free sulfur dioxide	0.113680
8	pH	0.108781
9	category_white	-0.101428
10	chlorides	-0.033861
11	citric acid	-0.026309

5.4 Comparación de Métricas

Se comparó el desempeño de dos modelos de regresión: uno que optimiza el Error Cuadrático Medio (MSE) mediante Regresión Lineal y otro que optimiza el Error Absoluto Medio (MAE) mediante Quantile Regressor.

Los resultados obtenidos fueron:

Comparación de métricas					
	Modelo	MAE	MSE	RMSE	R ²
0	Optimiza MSE	0.580924	0.544355	0.737804	0.286259
1	Optimiza MAE	0.578257	0.546363	0.739164	0.283625


MAE: El modelo que optimiza MAE obtuvo el menor Error Absoluto Medio (0.5783), lo cual era esperado, ya que fue entrenado específicamente para minimizar esta función de pérdida.

MSE y RMSE: El modelo de Regresión Lineal presentó los menores valores de MSE (0.5444) y RMSE (0.7378), indicando un mejor desempeño al reducir errores grandes.

R²: Ambos modelos obtuvieron un coeficiente de determinación muy similar (≈ 0.28), lo que significa que explican aproximadamente el 28% de la variabilidad de la calidad del vino.


5.5 Comparación de funciones de pérdida

La comparación entre ambos modelos muestra que las predicciones obtenidas al optimizar MSE y MAE son muy similares. En ambos casos, la mayoría de las estimaciones se concentran alrededor de las calidades más frecuentes (5, 6 y 7), mientras que las calidades extremas presentan mayor error de predicción.



5.6 Comparación de residuos

Los residuos se distribuyen alrededor del valor cero sin evidenciar un patrón sistemático. Esto indica que ninguno de los modelos presenta un sesgo importante en las predicciones. Las bandas diagonales observadas son consecuencia de que la variable de respuesta únicamente toma valores enteros de calidad.




6. Resultados

6.1 Comparación de modelos

Modelo	MAE (test)	RMSE	R ²	MSE
Regresión Lineal	0.5809	0.7378	0.2863	0.5444
LASSO (alpha=0.001)	0.5676	0.7377	0.2865	0.5442
Ridge (alpha=0.01)	0.5673	0.7327	0.2863	0.7627
AdaBoost	0.5570	0.7055	0.3473	0.4978
XGBoost	0.4845	0.6399	0.4632	0.4094
MLP	0.5323	0.6811	0.3918	0.4639
Random Forest	0.4459	0.6002	0.5276	0.3603

Comparativa de modelos — Predicho vs Real



La razón más profunda por la que los tres modelos lineales (RL, LASSO, Ridge) tienen un techo de desempeño (MAE $\approx$ 0.58) es que asumen que la calidad es una combinación lineal y aditiva de las variables fisicoquímicas. Pero la química del vino no funciona así: el impacto del alcohol en la calidad depende del nivel de azúcar residual y la densidad. Un vino con 14% de alcohol y alta azúcar residual puede ser peor que uno con 12% de alcohol y baja azúcar. Esta interacción no puede representarse con coeficientes lineales.

Random Forest la captura automáticamente: cada árbol puede construir nodos de división que condicionen el efecto de una variable al valor de otra. Cada árbol explora aleatoriamente

subconjuntos de variables, garantizando que se descubran interacciones que un solo árbol o un modelo lineal pasaría por alto.

6.2 Estabilidad gracias al bagging

A diferencia de AdaBoost y XGBoost (que construyen árboles secuencialmente, cada uno corrigiendo los errores del anterior), Random Forest usa bagging: entrena cada árbol en una muestra bootstrap independiente del dataset y promedia las predicciones. Este mecanismo tiene dos efectos:

- Reducción de varianza sin aumento de sesgo: cada árbol individual sobreajusta (alta varianza), pero el promedio de muchos árboles descorrelacionados cancela ese ruido.
- Robustez ante outliers y ruido: los puntos atípicos (calidades 3 y 9 con pocas muestras, o etiquetas ruidosas por desacuerdo entre catadores) solo influyen en los árboles cuya muestra bootstrap los incluye. En promedio, su peso se diluye en el ensemble. AdaBoost y XGBoost, en cambio les asignan más peso, lo que puede distorsionar el modelo.

6.3 Robustez ante el desbalance de clases

Con calidades extremas representando menos del 5% del dataset, los modelos de boosting tienden a sobreajustarse a esos casos raros (porque sus residuales son grandes, atrayendo la atención del siguiente árbol). Random Forest, al promediar sin ponderación adaptativa, produce predicciones más calibradas para la mayoría de los datos (calidades 5–7) sin sacrificar desempeño en los extremos.

6.4 Estimación OOB

Random Forest ofrece la puntuación Out-of-Bag (OOB): cada árbol predice solo los ~37% de los datos que no entraron en su muestra bootstrap. Promediar estas predicciones da una estimación del error de generalización sin tocar el conjunto de prueba. Que el R^2 OOB sea similar al R^2 en test confirma que el modelo no está sobreajustado y que la validación cruzada del GridSearchCV fue representativa.

6.5 ¿Por qué no MLP y XGBoost?

MLP y XGBoost también capturan no-linealidades, pero con desventajas en este contexto específico:

- MLP es una caja negra sin importancia de variables nativa, más sensible a la inicialización aleatoria, y muestra ventaja real con datasets de millones de muestras, no de 6,497.
- XGBoost con boosting secuencial amplifica los errores en clases minoritarias (calidades extremas), y en este experimento no se realizó una búsqueda exhaustiva de hiperparámetros comparable a la de Random Forest.
- Random Forest requiere menos ajuste fino: con parámetros razonables ($n_estimators \geq 100$, $max_features = \sqrt{\cdot}$) ya ofrece un desempeño robusto, mientras que XGBoost y MLP son más sensibles a sus hiperparámetros.